

Using more LaTeX packages

Conceptos básicos de estadística Parámetros: IMC

Población (universo o colectivo)

Es el conjunto total de ELEMENTOS de la misma naturaleza cualquiera que sea, que son de interés para un problema dado

- N = Representación de el tamaño de la población

muestra

Variable aleatoria:

Son fenómenos o características de los elementos de la población.

Función de valor real que tiene como dominio el espacio muestral de un experimento aleatorio.

Variables sobre las cuales tenemos un grado de incertidumbre respecto a los valores que puede tomar

Datos

Son los resultados observados de las variables aleatorias (Cuando se hace una medición)

Parámetro

Es la medición global de cualesquier característica de los elementos de la población.

Es un valor teórico asociado a la población.

Ejemplos

Población: Los niños y niñas de 0 a 5 años de edad localizados en Bogotá

Variables: género, edad, peso, talla, estrato, localidad, fecha, lugar de nacimiento..

Clasificación de variables

Cualitativas (categóricas)

Cuantitativas

Los valores de las observaciones son numéricas y en consecuencia, ordenables.

Discreta

Recorridos finitos numerables sin tomar valores intermedios e.g. conteos.

Continua

Recorridos infinitos no numerables e.g. la distribución normal

Escalas de medición

Cualitativas

Nominales: Clasificación de objetos o fenómenos mediante símbolos o signos (No hay orden o dirección). e.g.

- Nombre
- Número de la cédula
- Tipo de sangre
- Color de los ojos
- Número de camiseta de los jugadores

Los números en la lista anterior no pueden ser sometidos a operaciones matemáticas

Ordinales

Categorías ordenadas (Rangos, órdenes, escalamientos)

- Sabor de un yogurt

Cuantitativas

Intervalo

Los datos medidos en una escala ordinal para los cuales pueden clasificarse las distancias entre valores pero no existe un cero absoluto o no exista ausencia total de la característica

- Temperatura: a 0°C no deja de existir la temperatura
- Notas: se corre la escala e inicia desde 3.

Razón

Tiene todas las características de un intervalo, y además tiene un cero absoluto

Resumen y descripción de datos de una variable

Datos en bruto en forma de listas (o bases no son fáciles de usar para tomar decisiones)

- Se necesita algún tipo de organización

Para esto podemos utilizar gráficos de barras, gráficos de torta, o tablas de frecuencias.

Como agrupar los datos: Sturges

Si n no es demasiado grande, intervalos = \sqrt{n}

En caso contrario:

$$k = 1 + 3.322 \log(n) \quad (1)$$

k = intervalos de clase

Para la longitud de los intervalos:

$$L = \frac{\text{Dato mayor} - \text{Dato menor}}{n} \quad (2)$$

- A menudo es prueba y error

Tipos de frecuencias

- Absoluta: Conteo de observaciones que cae en cada intervalo.
- Relativa: $\frac{\text{Absoluta}}{n}$.
- Acumulada: Suma de las frecuencias absolutas
- Relativa acumulada: Suma de las frecuencias relativas.

Características a revisar de las distribuciones

- Distribución
- Localización (sesgo)
- Dispersión

Medidas de localización

Media aritmética:

Si $x_1, x_2, x_3, \dots, x_n$ es una muestra de una población de tamaño N entonces la media es \bar{x}

Media poblacional

$$\mu = \frac{\sum_{i=1}^n x_i}{N} \quad (3)$$

Estimador muestral

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \quad (4)$$

Características:

- Es fácil de obtener
- Medida no robusta: Afectada por valores extremos o datos atípicos.

Propiedades de la media aritmetica:

Si $x_1, x_2, x_3, \dots, x_n$ es una muestra de una poblacion de tamaño N entonces la media es N, entonces

$$\sum_{i=1}^n (x_i + y_i) = \sum_{i=1}^n x_i + \sum_{i=1}^n y_i \quad (13)$$

$$\sum_{i=1}^n x_i = x_1 + x_2 + x_3 + \dots + x_n \quad (5) \quad \sum_{i=1}^n (x_i + y_i) = (x_1 + y_1) + (x_2 + y_2) + (x_3 + y_3) + \dots + (x_n + y_n) \quad (14)$$

Si $x_i = c$ y a su vez c es constante, entonces

$$\sum_{i=1}^n x_i = \sum_{i=1}^n c = c + c + c + \dots \quad (6) \quad \sum_{i=1}^n (x_i + y_i) = (x_1 + x_2 + \dots + x_n) + (y_1 + y_2 + \dots + y_n) \quad (15)$$

Entonces

$$\sum_{i=1}^n x_i = nc \quad (7) \quad \sum_{i=1}^n (x_i + y_i) = \sum_{i=1}^n x_i + \sum_{i=1}^n y_i \quad (16)$$

Si $x_1, x_2, x_3, \dots, x_n$ y $y_1, y_2, y_3, \dots, y_n$ son sucesiones de numeros;

• *Ejemplo:*

$$\sum_{i=1}^5 2 = 2 + 2 + 2 + 2 + 2 \quad (8)$$

5.

$$\sum_{i=1}^n (x_i - y_i) = \sum_{i=1}^n x_i - \sum_{i=1}^n y_i \quad (17)$$

Si c es una constante que multiplica las observaciones:

$$\sum_{i=1}^n cx_i = c \sum_{i=1}^n x_i \quad (9)$$

$$\sum_{i=1}^n (x_i - \bar{x}) = 0 \quad (18)$$

$$\sum_{i=1}^n cx_i = c \cdot x_1 + c \cdot x_2 + c \cdot x_3 + \dots + c \cdot x_n \quad (10)$$

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \quad (19)$$

$$\sum_{i=1}^n cx_i = c (x_1 + x_2 + x_3 + \dots + x_n) \quad (11)$$

$$\sum_{i=1}^n (x_i - \bar{x}) = \frac{n}{n} \sum_{i=1}^n x_i - n\bar{x} \quad (20)$$

$$\sum_{i=1}^n cx_i = c \sum_{i=1}^n x_i \quad (12)$$

$$\sum_{i=1}^n (x_i - \bar{x}) = n\bar{x} - n\bar{x} \quad (21)$$

Si $x_1, x_2, x_3, \dots, x_n$ y $y_1, y_2, y_3, \dots, y_n$ son sucesiones de numeros;

$$\sum_{i=1}^n (x_i - \bar{x}) = 0 \quad (22)$$

6.

promedio de y en funcion de promedio de x en regresion lineal simple

Si $y_i = a + bx_i$ siendo a y b constante

$$\bar{y} = a + b\bar{x} \quad (23)$$

En efecto:

$$\sum_{i=1}^n y_i = \sum_{i=1}^n (a + bx_i) \quad (24)$$

$$\sum_{i=1}^n y_i = \sum_{i=1}^n a + \sum_{i=1}^n bx_i \quad (25)$$

$$\sum_{i=1}^n y_i = na + b \sum_{i=1}^n x_i \quad (26)$$

$$\frac{\sum_{i=1}^n y_i}{n} = \frac{na}{n} + b \frac{\sum_{i=1}^n x_i}{n} \quad (27)$$

$$\bar{y} = a + b\bar{x} \quad (28)$$

La mediana

Es el valor central (es el dato de la variable que esta en el centro de la misma). Deja por encima y por debajo mitad y mitad de las observaciones.

Calculo de la mediana

Depende si el conjunto es par o impar:

Si $x_1, x_2, x_3, \dots, x_n$ Son los valores ordenados en una muestra de una poblacion de tamaño N:

$\hat{x} = \frac{x_{n/2} + x_{n+1/2}}{2}$ si n es par

$\hat{x} = x_{n=1/2}$ si n es impar

Es un estimador robusto, no se ve afectado por valores extremos

Ejemplo

Edad de ninos

x1 <- c(6,7,8,9,10)

n es impar, entonces $\hat{x} = x_{n+1/2} = x_{6/2} = x_3 = 8$

De la muestra analizada la mitad de los ninos tienen entre 6 y 8 años, y la otra mitad entre 8 y 10 años.

Moda

- El valor que más se repite
- Usada para valores numéricos o categóricos

e.g. Cual es el color más frecuente en los ojos.

Medidas de dispersión o variación

Varianza

Uno de los problemas es que la unidad de medida queda al cuadrado, e.g. si se miden cm, la varianza tiene unidades de cm^2 :

- Varianza poblacional:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N} \quad (29)$$

- Varianza muestral:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (30)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - 2x_i\bar{x} + \bar{x}^2}{n - 1} \quad (31)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2}{n - 1} \quad (32)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - 2\bar{x} \frac{n}{n} \sum_{i=1}^n x_i + n\bar{x}^2}{n - 1} \quad (33)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - 2\bar{x}n\bar{x} + n\bar{x}^2}{n-1} \quad (34)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2}{n-1} \quad (35)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - n\bar{x}^2}{n-1} \quad (36)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2}{n-1} - \frac{n\bar{x}^2}{n-1} \quad (37)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2}{n-1} - \frac{n}{n-1} \left(\frac{\sum_{i=1}^n x_i}{n} \right)^2 \quad (38)$$

$$s^2 = \frac{\sum_{i=1}^n x_i^2}{n-1} - \frac{1}{n-1} \frac{(\sum_{i=1}^n x_i)^2}{n} \quad (39)$$

En algunos casos puede ser más conveniente calcular la varianza de esta forma.

Coefficiente de variación

$$CV = \frac{s}{\bar{x}} \cdot 100\%$$

Si CV es igual o menor a 5% hay homogeneidad

si esta entre 5% y 20% los datos son medianamente homogéneos

Si CV mayor a 20% hay heterogeneidad

Rango

medida no robusta, si hay datos atípicos se ve muy afectado

rango intercuartílico

boxplot

Cuartiles

Se divide en cuatro partes porcentuales el conjunto de observaciones.

Se calcula de la siguiente manera.

Se ordena la muestra y se toma la posición que corresponde.

$$Q_k = k \cdot \frac{n}{4} \quad k = 1, 2, 3$$

Deciles

Se divide en diez partes porcentualmente iguales

$$D_k = \frac{n}{10} \quad 1, 2, 3, \dots, 9$$

Percentiles

es más detallado, nos da más acceso a distintos puntos de la distribución

$$P_k = \frac{n}{100} \quad 1, 2, 3, \dots, 99$$

Coefficientes de asimetría de Fisher

Permite interpretar la forma de la distribución, respecto a ser o no asimétrica

Coefficiente de curtosis

Mide el grado de aplastamiento o apuntamiento de la gráfica de la distribución.

Otras medidas de centralización

Desviación media absoluta

$$DM = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n} \quad (40)$$

Media ponderada

Media geométrica

Media armónica

Sirve en diseño de experimentos para aproximar el número de repeticiones en todo el experimento cuando el diseño es desbalanceado.

Ejemplo en excel

Tabla de pesos de mujeres en una empresa

1. construcción de la tabla de frecuencias

- Definición de los intervalos: podemos utilizar la siguiente ecuación:

$$k = 1 + 3.322 \log_{10}(n) \quad (41)$$

Para esta muestra de 50 pesos de mujeres:

$$k = 1 + 3.322 \log_{10}(50) \quad (42)$$

$$k = 6.6 \approx 7 \quad (43)$$

Vamos a usar 7 intervalos, para saber la longitud dividimos el rango en el número de intervalos.

Para hallar el rango podemos importar los datos a R:

```
tablaPesos <- read.table("TABLAPESOS.txt", header = T)
```

Y luego preguntar sobre el valor máximo y el mínimo:

```
max(tablaPesos)
```

```
## [1] 72
```

```
min(tablaPesos)
```

```
## [1] 53
```

Podemos entonces calcular la longitud de cada intervalo:

```
(max(tablaPesos)-min(tablaPesos))/7
```

```
## [1] 2.714286
```

Obtenemos una longitud de intervalo de $2.71 \approx 3$

Los intervalos entonces serían:

```
## intervalo valores
## 1      1    53 55
## 2      2    56 58
## 3      3    59 61
## 4      4    62 64
## 5      5    65 67
## 6      6    68 70
## 7      7    71 73
```

En excel:

- Usamos los límites superiores de los intervalos

- Datos, análisis de datos, histograma, aceptar, seleccionar rango de entrada, rango de clases son los límites superiores. Al hacer esto, excel genera una tabla como la siguiente:

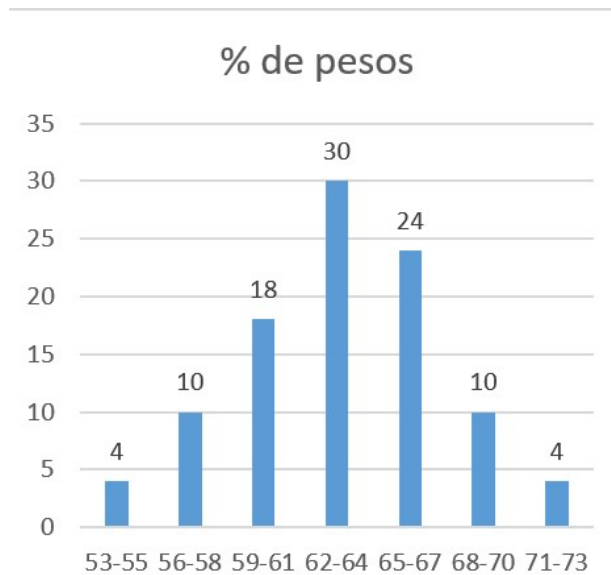
Clase	Frecuencia
55	2
58	5
61	9
64	15
67	12
70	5
73	2
y mayor...	0

Figure 1: tabla de frecuencias en excel

Luego, a partir de esta tabla podemos calcular todas las frecuencias, la frecuencia absoluta (f_i), frecuencia relativa (f_r), la frecuencia absoluta acumulada (F_i) y la frecuencia relativa acumulada (F_r):

	absoluta	relativa	abs. acumul.	rel. acumul.
intervalo	fi	fr	Fi	Fr
53-55	2	0.04	2	0.04
56-58	5	0.1	7	0.14
59-61	9	0.18	16	0.32
62-64	15	0.3	31	0.62
65-67	12	0.24	43	0.86
68-70	5	0.1	48	0.96
71-73	2	0.04	50	1

Luego a partir de esta tabla de frecuencias, utilizando las columnas de intervalo y % de frecuencia podemos construir un histograma como el siguiente:



Para hacer una operación análoga en R podemos crear los intervalos de la siguiente manera:

```
mins <- seq(53,71, by = 3)
maxs <- seq(55,73, by = 3)
```

Luego, podemos juntar las dos columnas de límites inferiores y superiores de intervalo en la tabla TDF:

```
TDF <- data.frame(min = mins,
                  max = maxs )
TDF
```

```
##   min max
## 1  53  55
## 2  56  58
## 3  59  61
## 4  62  64
## 5  65  67
## 6  68  70
## 7  71  73
```

Luego podemos iterar a lo largo de las filas de `tablasDefrecuencias` buscando cuantos elementos de `tablaDePesos` están dentro del intervalo definido por cada fila:

```
for(i in 1:nrow(TDF)) {
  TDF$Freq[i] <-
    length(
      which(
mins[i] <= tablaPesos & tablaPesos<= maxs[i]
      )
    )
}
```

Podemos luego calcular la frecuencia relativa dividiendo por el total de observaciones:

```
TDF$fr <-TDF$Freq/
  sum(TDF$Freq)
```

TDF

```
##   min max Freq  fr
## 1  53  55    2 0.04
## 2  56  58    5 0.10
## 3  59  61    9 0.18
## 4  62  64   15 0.30
## 5  65  67   12 0.24
## 6  68  70    5 0.10
## 7  71  73    2 0.04
```

Luego podemos calcular la frecuencia absoluta y relativa acumuladas para cada intervalo de manera ascendente:

```
for(i in 1:nrow(TDF)){
  TDF$Fi[i] <- sum(TDF$Freq[1:i])
}
```

Podemos hacer lo mismo para la frecuencia relativa acumulada (F_r):


```
for(i in 1:nrow(TDF)){
  TDF$Fr[i] <- sum(TDF$fr[1:i])
}
```

Una vez tenemos la tabla de frecuencias completa, podemos hacer la gráfica de frecuencias porcentuales:

```
library(ggplot2)
intervalos <- factor(paste(TDF$min,'-',TDF$max))

ggplot(TDF,
  aes(x = intervalos,
      y = fr*100,
      fill=intervalos,
      label = round(fr*100,2)
    )
  ) +
  geom_bar(stat="identity") +
  xlab("intervalo") +
  ylab('% frecuencia relativa')+
  theme_minimal()
```

```
geom_label(aes(fill = intervalos),
           colour = "white",
           fontface = "italic")
```



Calculo de medidas descriptivas

```
mean(tablaPesos$pesos)
```

```
## [1] 63.2
```

```
quantile(tablaPesos$pesos)
```

```
##    0%   25%   50%   75%  100%
## 53.0  61.0  63.5  66.0  72.0
```

El 75% de las mujeres pesan entre 53 y 66 kg. El 25% restante pesa entre 66 kg y 72 kg

- la varianza: Es importante calcular la varianza muestral y no la varianza poblacional, dado que no se puede saber la poblacional (σ^2) si no su estimador (s^2).
- Algunos paquetes hacen calculos con la varianza poblacional

En R: 'The denominator n - 1 is used which gives an unbiased estimator of the (co)variance for i.i.d. observations.'

```
var(tablaPesos$pesos)
```

```
## [1] 17.10204
```

Para calcular la varianza poblacional:

```
pesos <- tablaPesos$pesos
sum((pesos - mean(pesos))^2)/length(pesos)
```

```
## [1] 16.76
```

para el calculo de la desviacion estandar:

```
sd(pesos)
```

```
## [1] 4.135461
```

```
sqrt(var(pesos))
```

```
## [1] 4.135461
```

Interpretación:

Varianza: Tiene unidades al cuadrado. Tendriamos que tener otro grupo de comparación, con una medición similar.

Desviacion estandar: la desviacion de las observaciones respecto al promedio es de 4.14 unidades de masa (kg).

Para calcular otros estadísticos descriptivos podemos utilizar en excel:

- Datos > Análisis de datos > Estadística descriptiva > Se selecciona rango de entrada y de salida.

Se obtiene la siguiente tabla:

Dentro de esta tabla está el error típico

Error típico - error estándar

$$\frac{s}{\sqrt{(n)}} \quad (44)$$

En este caso:

```
sd(pesos)/sqrt(50)
```

```
## [1] 0.5848426
```

Se utiliza para inferencia, para intervalos de confianza. En diseño de experimentos sirve para el cálculo de tamaño de muestra. Se espera que no aumente el número de réplicas si no disminuye lo suficiente el error típico.

Columna1	
Media	63.2
Error típico	0.5848426
Mediana	63.5
Moda	64
Desviación estándar	4.1354614
Varianza de la muestra	17.102041
Curtosis	-0.0713723
Coeficiente de asimetría	-0.2023508
Rango	19
Mínimo	53
Máximo	72
Suma	3160
Cuenta	50

Figure 2: Cuadro de estadística descriptiva en excel

```
library(e1071)
kurtosis(pesos)
```

```
## [1] -0.2936688
```

```
skewness(pesos)
```

```
## [1] -0.1903716
```

La distribución de pesos tiene una curtosis < 3 , lo cual indica que es más aplanada que una distribución normal, o tiene hombros más pesados.

Además, tiene un coeficiente de asimetría cercano a cero, lo cual indica un ligero sesgo con cola hacia valores menores de peso.

```
range(pesos)
```

```
## [1] 53 72
```

```
range(pesos)[2] - range(pesos)[1]
```


```
## [1] 19
```

La persona que más peso tiene, tiene 19 kg más que la persona de menos peso.

También podemos graficar la frecuencia acumulada:

```
library(ggplot2)
intervalos <- factor(paste(TDF$min, '-', TDF$max))

ggplot(TDF,
       aes(x = intervalos,
           y = Fr*100,
           fill=intervalos,
           label = round(Fr*100,2)
        )
    ) +
  geom_bar(stat="identity") +
  xlab("intervalo") +
  ylab('% frecuencia relativa') +
  geom_label(aes(fill = intervalos,
                 colour = "white",
                 fontface = "italic"))
```



el 86% de las mujeres pesan entre 53 y 67 kg.

Desviación media absoluta

Ejemplo de edades

Este ejemplo está en el código llamado `medidasdescriptivas.R`

Aun así podemos

Proporción

Es similar al promedio, para variables de tipo cualitativo:

$$\hat{p} = \frac{\sum_{i=1}^n x_i}{n}$$

Con esta ecuación es posible calcular las proporciones.

$$x_i = \begin{cases} 1 & \text{Si cumple la condicion} \\ 0 & \text{Si no} \end{cases}$$

Para calcular la proporción de varias variables cualitativas podemos utilizar la función `crosstable` del paquete `gmodels`.

También se puede buscar asociación entre las variables. Existen pruebas de asociación tales como la de *ji* cuadrado.

Asociación

‘La existencia de asociación entre dos variables indicaría que la distribución de los valores de una de las dos variables difiere en función de los valores de la otra’

La asociación entre 2 variables de diferente tipo se puede encontrar:

- El caso de dos variables categóricas # Prueba de independencia chi cuadrado

La prueba de independencia de chi cuadrado de termina si hay alguna asociación entre variables categóricas (Si están asociadas o son independientes) Es una prueba no paramétrica.

Esta prueba utiliza una tabla de contingencia para analizar los datos. Ésta tabla es un arreglo en el cual los datos son clasificados de acuerdo a dos variables categóricas. Las categorías de una variable aparecen en las filas, y las categorías para la otra variable aparecen en las columnas. Cada variable debe tener dos o más categorías o niveles. Cada celda refleja el conteo total de casos para un par específico de categorías.

NOTA

Existen varias pruebas con el nombre ‘prueba chi-cuadrado’ además de la prueba de independencia de chi cuadrado. Es útil revisar el contexto de los datos y la pregunta de investigación para asegurar cual forma de la prueba chi cuadrado se está utilizando.

Usos de la prueba

la prueba de independencia de chi cuadrado se utiliza comúnmente para probar:

- Independencia estadística o asociación entre dos o más variables categóricas.

La prueba de independencia chi-cuadrado solo puede comparar variables categóricas. No puede hacer comparaciones entre variables continuas o entre variables continuas y categóricas. Además, La prueba de independencia chi-cuadrado solo *evalúa asociaciones* entre variables categóricas, y no puede inferir nada sobre causalidad.

requerimientos de los datos

Los datos deben cumplir las siguientes condiciones:

1. Tener dos variables categóricas.
2. Dos o más categorías (grupos) o niveles para cada variable.
3. Independencia de las observaciones.
 - No existen relaciones entre los sujetos de cada grupo
 - Las variables categóricas no están ‘emparejadas’ de manera.
4. Tamaño de muestra relativamente grande.
 - Se espera por lo menos una frecuencia de 1 en cada celda.
 - Se esperan frecuencias de por lo menos 5 en la mayoría (80%) de celdas.

Hipotesis

La hipótesis nula (H_0) y la hipótesis alternativa (H_1) de la prueba de independencia de la prueba de chi cuadrado pueden ser expresadas de dos maneras diferentes pero equivalentes:

H_0 : La [variable 1] es independiente de la [variable 2]

H_1 : La [variable 1] no es independiente de la [variable 2]

O

H_0 : La [variable 1] No está asociada con [variable 2]

H_1 : La [variable 1] está asociada con [variable 2]

Estadístico de la prueba

El estadístico de la prueba de independencia de chi-cuadrado se denota como X^2 y se calcula de la siguiente manera:

$$X^2 = \sum \sum$$

Calculo en R

```
library(readxl)
datos <- read_excel("./datostabla.xlsx")

tabla<-table(datos)

library(gmodels)
CrossTable(datos$nivelescola,datos$ingresos)
```

```
##
##
##      Cell Contents
## |-----|
## |                      N |
## | Chi-square contribution |
## |      N / Row Total |
## |      N / Col Total |
## |      N / Table Total |
## |-----|
##
##
## Total Observations in Table:  50
```

	datos\$ingresos			
datos\$nivelescola	alto	bajo	medio	Row Total
posgrado	8	0	0	8
	16.849	4.000	0.000	20.849
	1.000	0.000	0.000	1.000
	0.615	0.000	0.000	0.615
	0.160	0.000	0.000	0.160
primaria	0	5	5	10
	2.600	0.000	2.817	5.417
	0.000	0.500	0.500	1.000
	0.000	0.200	0.417	0.617
	0.000	0.100	0.100	0.200
secundaria	4	20	7	31
	2.045	1.306	0.026	3.377
	0.129	0.645	0.226	1.000
	0.308	0.800	0.583	1.691

	alto	bajo	medio	Row Total
universitario	1	0	0	1
	2.106	0.500	0.240	2.846
	1.000	0.000	0.000	1.000
	0.077	0.000	0.000	0.077
	0.020	0.000	0.000	0.020
Column Total	13	25	12	50
	0.260	0.500	0.240	1.000

```
chisq.test(tabla)$statistic
```

```
## Warning in chisq.test(tabla): Chi-squared approximation
```

```
## X-squared
## 34.40964
```

```
chisq.test(tabla)
```

```
## Warning in chisq.test(tabla): Chi-squared approximation
```

```
##
## Pearson's Chi-squared test
##
## data:  tabla
## X-squared = 34.41, df = 6, p-value = 5.607e-06
```

Warning in chisq.test(tabla) : Chi-squared approximation may be incorrect Aparece porque hay celdas con frecuencias de cero. Es aconsejable hacer la aproximación de fisher para muestras como esta.

Los grados de libertad de la prueba seria (filas-1)(columnas-1) = 6. 0.160

Existen otros estadísticos como el phi y el Cramer: